PROYECTO 01 | REINFORCEMENT LEARNING

De tablas Q a redes Q profundas

Evidencia experimental real en CartPole-v1 y Acrobot-v1

42 ENTRENAMIENTOS

5,16 M PASOS

3 SEMILLAS / GRUPO

Q-learning tabular | DQN | OFAT y ablación | Evaluación final de 100 episodios

Resultados recalculados de los CSV y configuraciones del repositorio entregado

La representación y la estabilidad importan más que el nombre del algoritmo

414,69

CartPole | Tabular 10 bins

200k pasos; media de 3 semillas; 1/3 supera 475

-88,39

Acrobot | Target 250

100k pasos; las 3 semillas superan -100

42

corridas completas

4.200 episodios finales, 100 por corrida

Un resultado positivo aislado no es convergencia; una falla explicada también es evidencia.

Tres preguntas falsables para guiar el análisis

RQ1 | Discretización

¿Qué granularidad equilibra aliasing y cobertura del espacio en CartPole?

RQ2 | Presupuesto

¿Qué se observa al entrenar 80k y 200k pasos con un calendario de exploración proporcional?

RQ3 | Estabilidad

¿Cómo cambia Acrobot al modificar learning rate, sincronización y red objetivo?

Hipótesis = contraste medible. Interpretación = datos + mecanismo plausible + límites.

Por qué estos entornos y no otros

Entorno	Observaciones y acciones
CartPole-v1	4 continuas; 2 acciones discretas
Acrobot-v1	6 continuas; 3 acciones discretas
BipedalWalker / MuJoCo	torques continuos; solo análisis
Atari en píxeles	alta dimensión; no Q-table

Umbrales del curso

CartPole

≥ 475

Acrobot

≥ -100

Criterios del profesor; no confundir con los defaults de Gymnasium.

La ecuación de Bellman conecta ambos enfoques

$$Q(s,a) = E[\, r + \gamma \max_{a'} Q(s',a') \mid s,a \,]$$

Q-learning tabular

Actualiza una celda de Q tras cada transición. Necesita discretizar un estado continuo.

DQN

Aproxima Q(s,a) con una red; optimiza una pérdida temporal mediante muestras del replay.

El número de bins crea un compromiso entre aliasing y cobertura

1.296

6 bins/dimensión

2.592 valores Q, 2 acciones

10.000

10 bins/dimensión

20.000 valores Q, 2 acciones

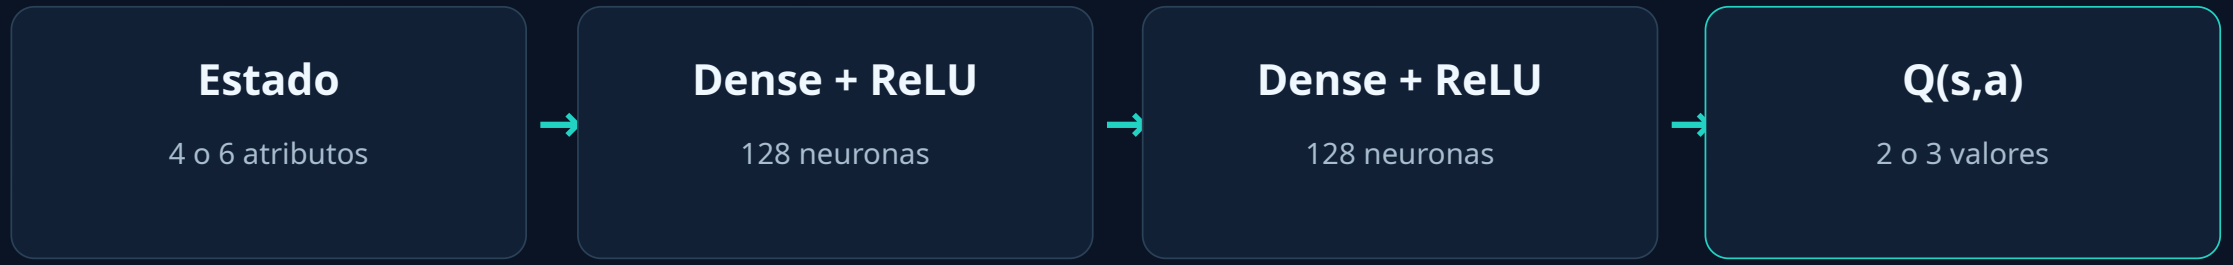
160.000

20 bins/dimensión

320.000 valores Q, 2 acciones

Mejor observado: 10 bins. Muy grueso = aliasing; muy fino = visita dispersa.

La red aprende valores de acción, no probabilidades de acción



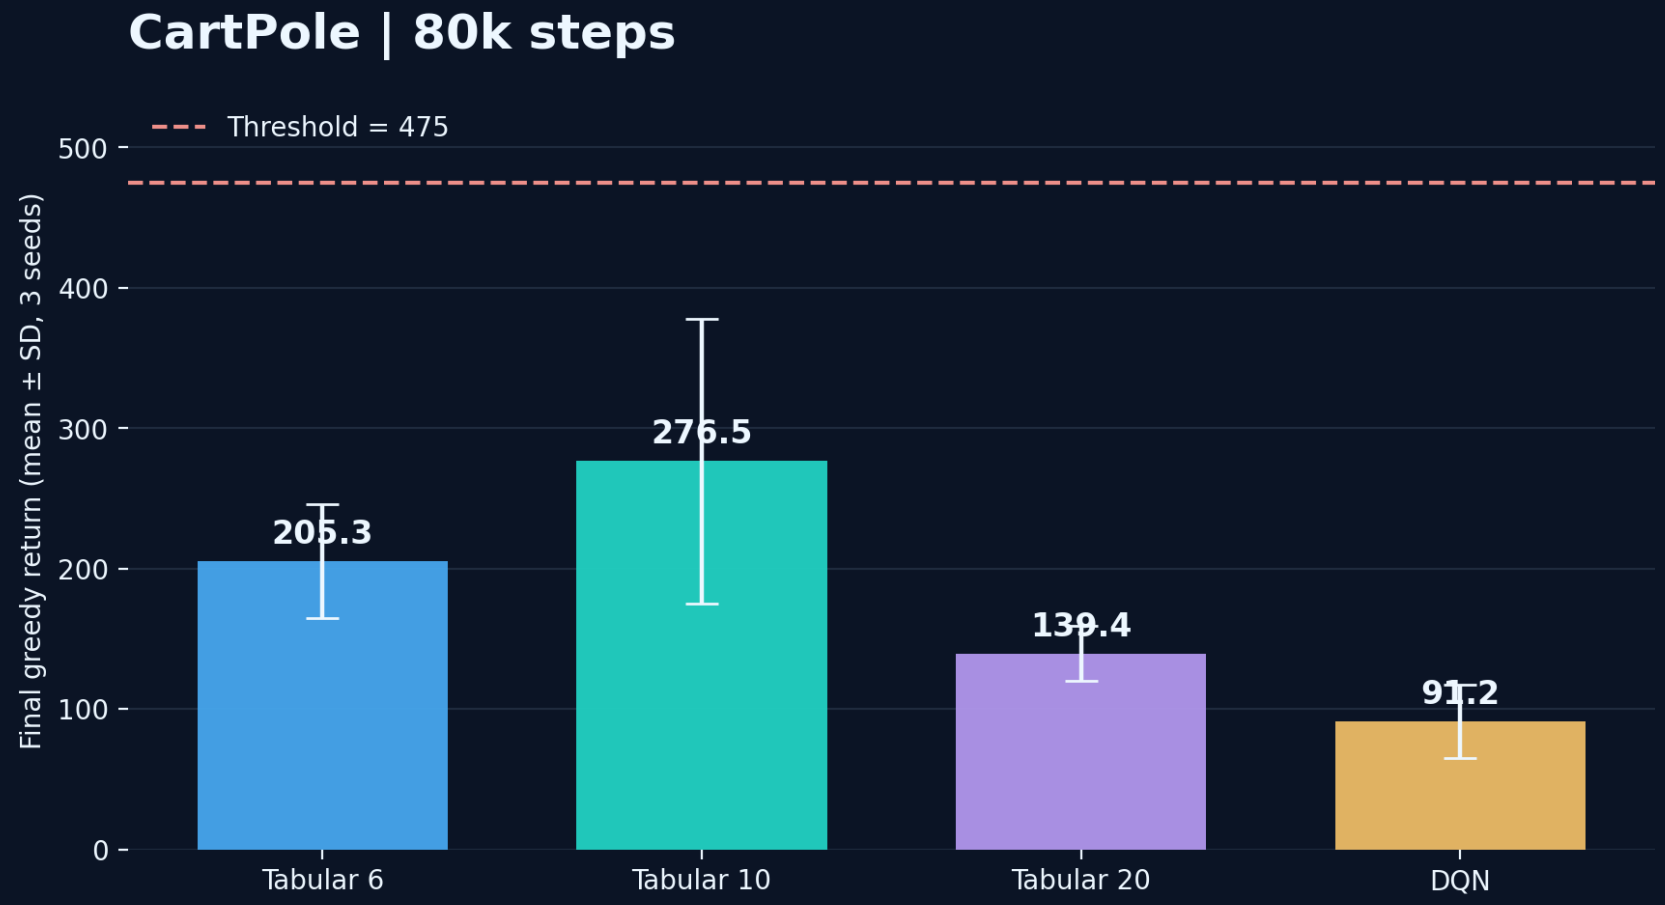
Componente	Implementación registrada
Replay buffer	50.000 transiciones; batch 64
Optimización	Adam, Huber, norma gradiente 10
Actualizaciones	cada 4 pasos; inicio al paso 1.000

Mismo presupuesto de pasos dentro de cada comparación

03	**semillas: 11, 22, 33**
10	**episodios greedy por checkpoint**
100	**episodios greedy finales por semilla**
4.200	**episodios de prueba final, 42 corridas**

La semilla de entrenamiento es la unidad de replicación; no los 100 episodios finales.

Con 80.000 pasos, Q-learning de 10 bins supera al DQN configurado



276,47

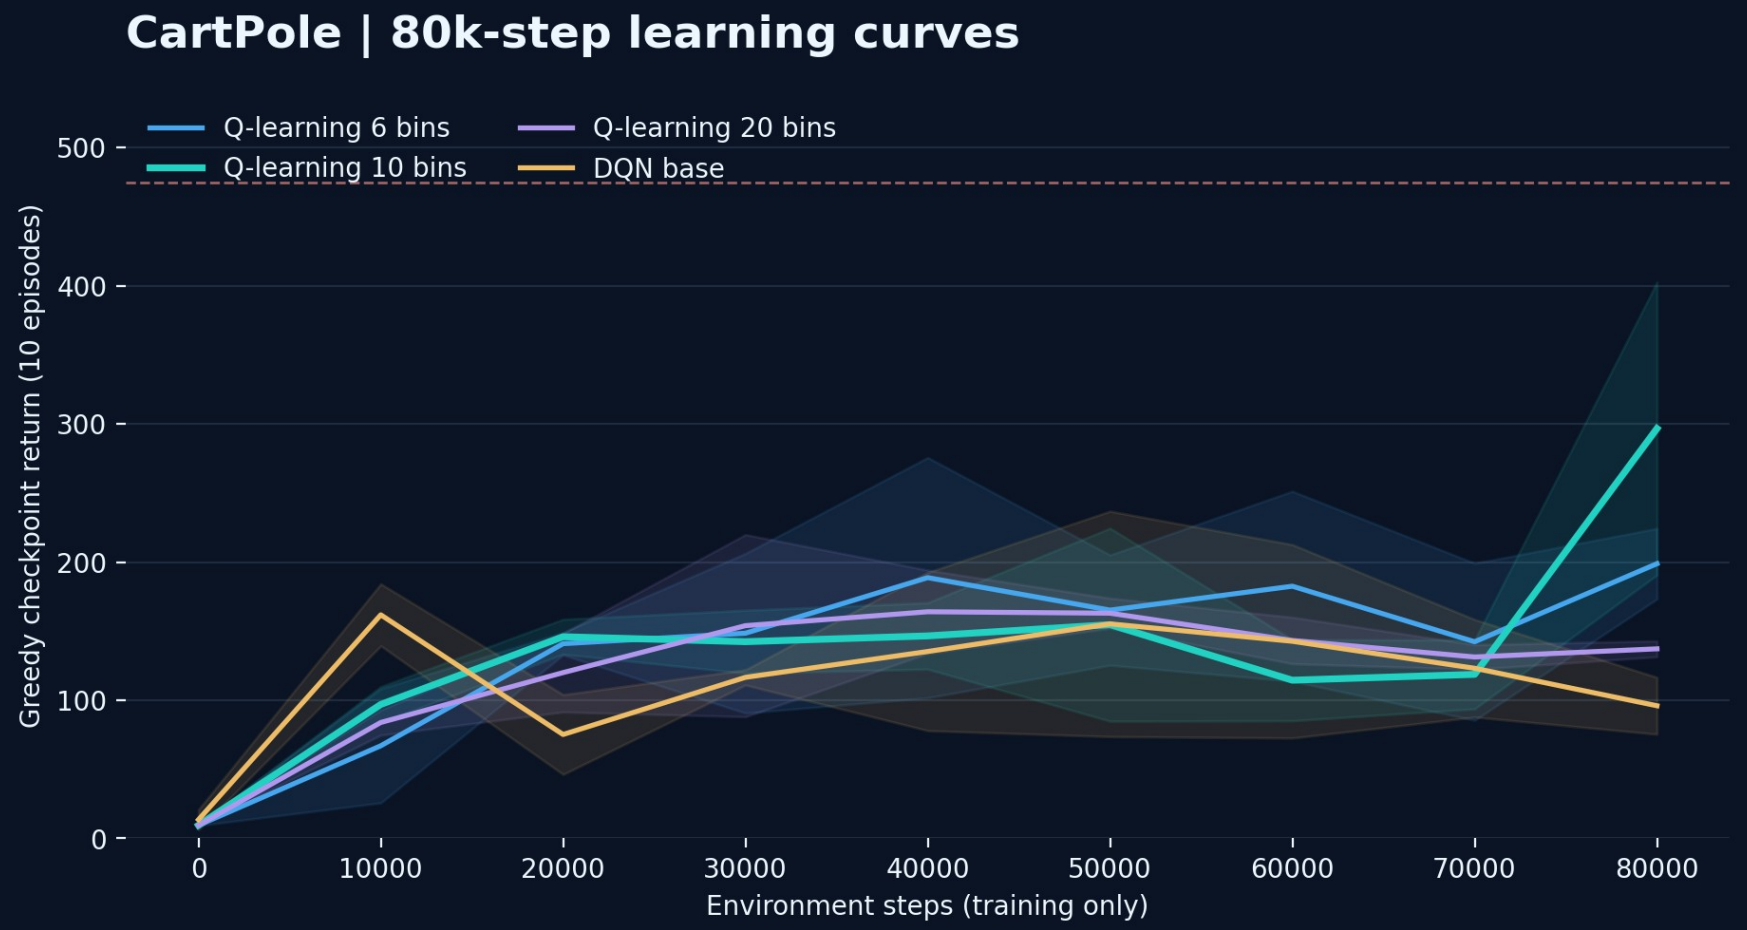
Tabular 10

91,24

DQN base

0/3 semillas alcanzaron 475 en TODAS las variantes.

Las curvas muestran dinámica de aprendizaje, no éxito final



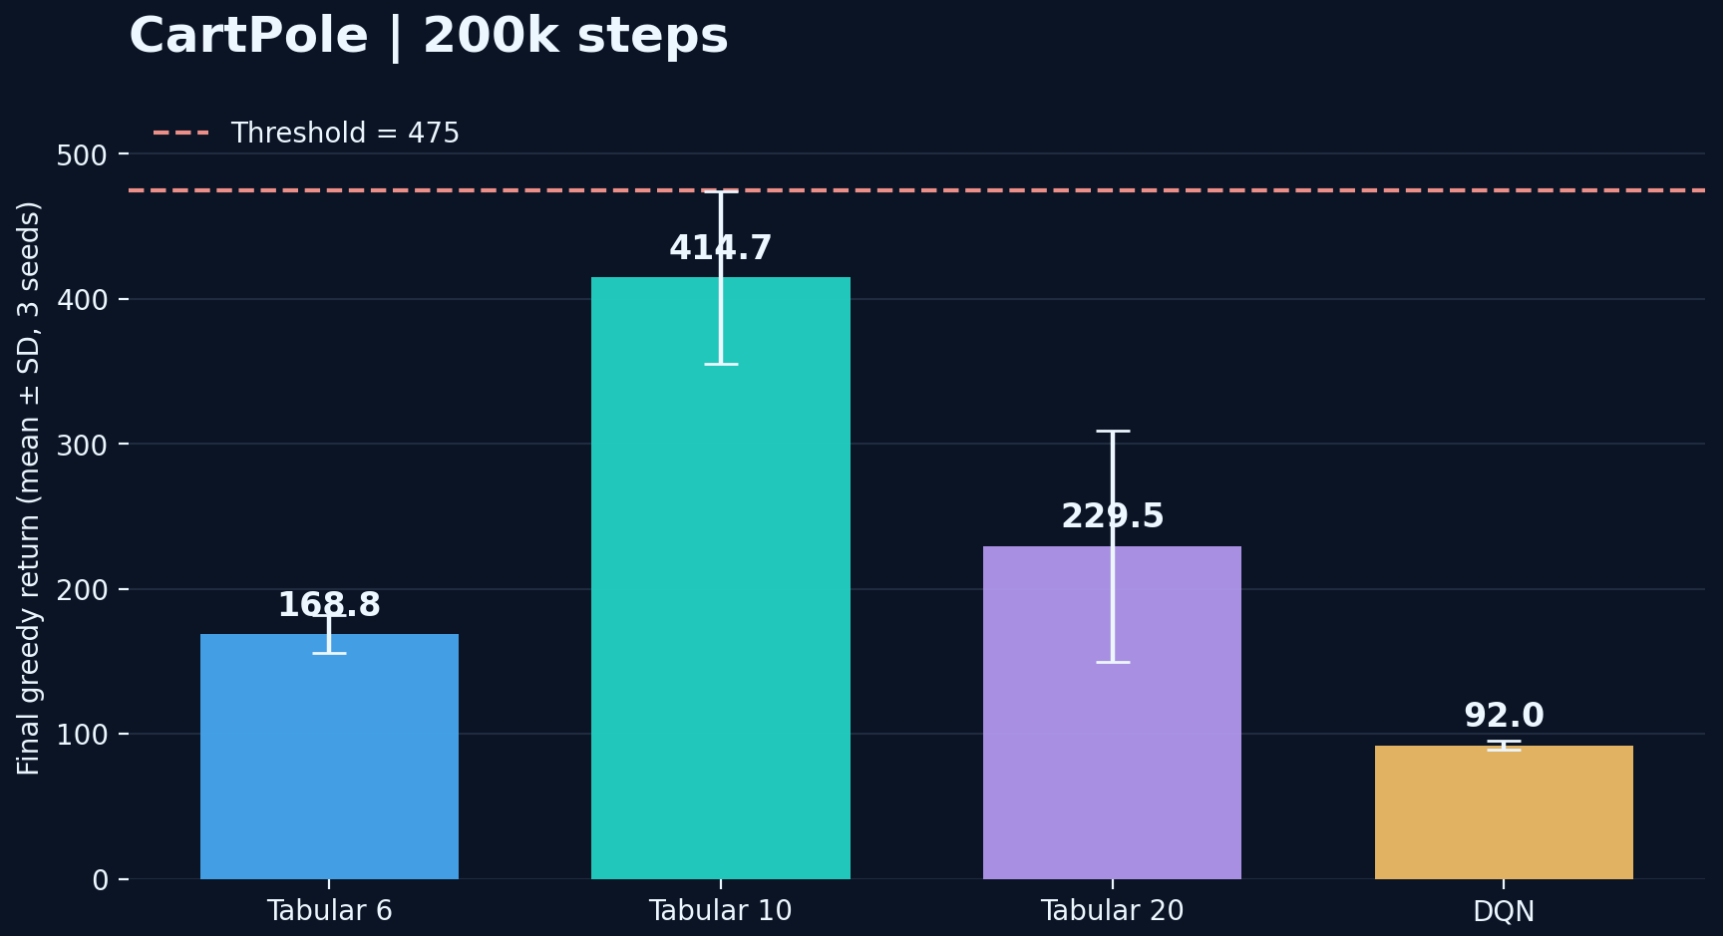
Lectura correcta

Puntos: media de 10 episodios greedy por seed.

Límite

Una curva alta no sustituye 100 episodios finales.

Ampliar a 200.000 pasos favorece 10 bins, no asegura convergencia



414,69

10 bins | 3 semillas

1 / 3

superó 475

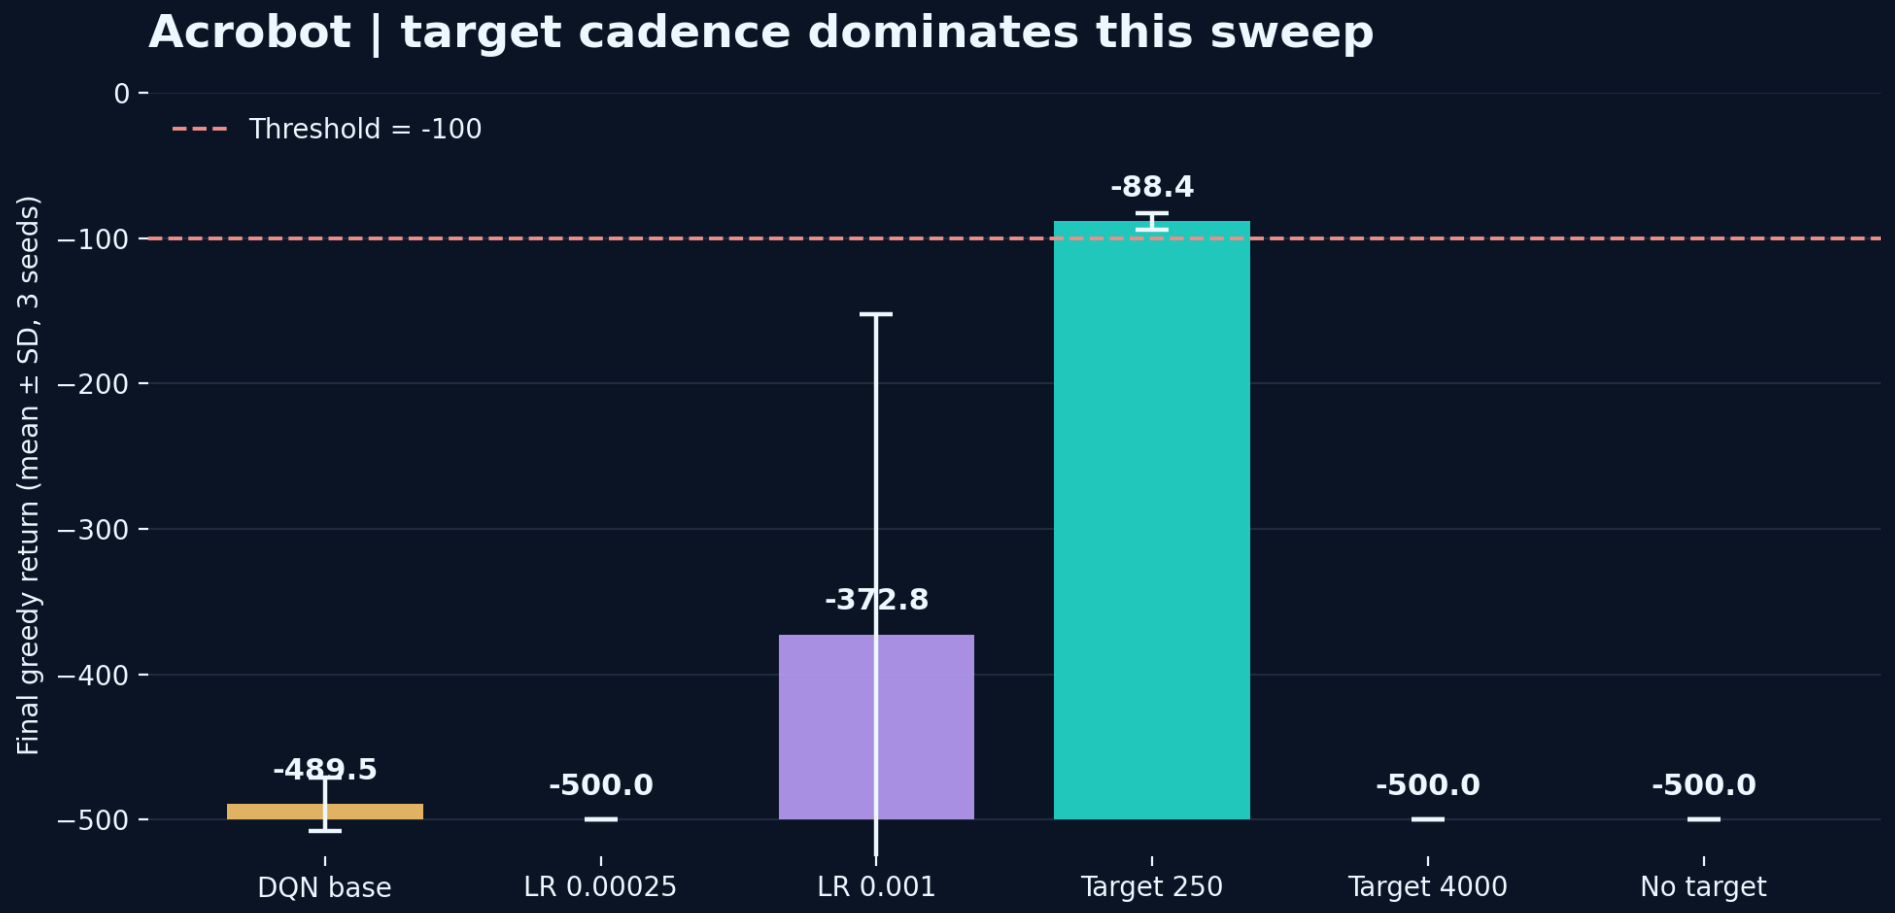
Ejecuciones nuevas; el decaimiento de epsilon también se alargó.

El promedio 414,69 oculta diferencias importantes entre repeticiones

Semilla 11	Semilla 22	Semilla 33
369,28	392,78	482,02
NO SUPERÓ 475	NO SUPERÓ 475	SUPERÓ 475

Decisión científica: éxito en una semilla ≠ éxito reproducible.

La frecuencia de sincronización modifica radicalmente el resultado



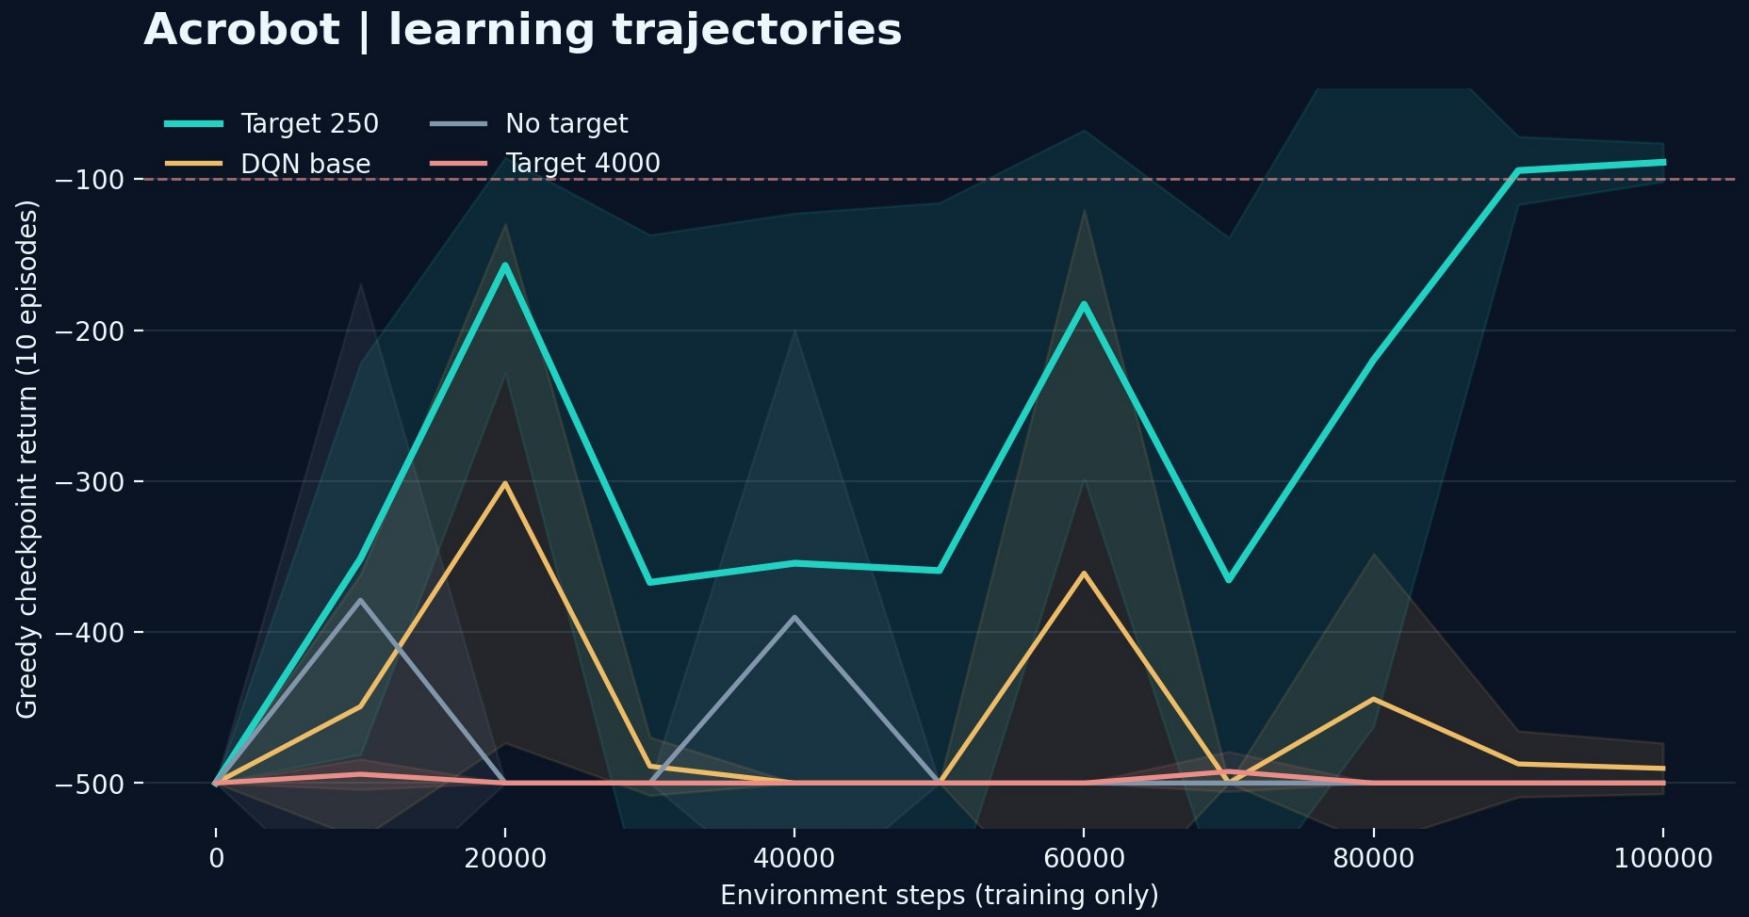
-88,39

target cada 250

3 / 3

semillas superan -100

El checkpoint puede mejorar y después empeorar



Caso clave

DQN base

una semilla cruzó -100 en un checkpoint, pero finalizó en -468,42.

≠ Convergencia

Lo que sí demuestra y lo que todavía no demuestra este experimento

Evidencia consistente

En CartPole, 10 bins superó al DQN probado a 80k y 200k. En Acrobot, target 250 pasó en 3/3 semillas.

No concluir

Que Q-learning siempre supera DQN; que 200k aísla el efecto de pasos; o que la ablación demuestra necesidad universal del target.

Una defensa fuerte demuestra resultados, explica fallos y delimita exactamente la inferencia.

MATERIAL DE RESPALDO | NO INCLUIR EN LOS 10 MINUTOS

Apéndices técnicos

Preguntas difíciles, trazabilidad del código, inferencia y reproducibilidad.

Usar solo si el docente pide profundizar

terminated ≠ truncated

$$\text{fin_episodio} = \text{terminated} \ \text{OR} \ \text{truncated}$$

$$y = r + \gamma\,(1 - \text{terminated})\,\max Q_{\text{target}}(s', a')$$

terminated = True

Estado terminal real: anular bootstrap.

truncated = True

Límite temporal: terminar episodio, pero mantener bootstrap.

Hiperparámetros que debes poder defender

Parámetro	Valor y razón
Gamma	0,99; recompensa futura valorada
Alpha tabular	0,15; actualización TD por muestra
DQN	128-128 ReLU; Adam + Huber
Replay	50.000; batch 64; muestreo aleatorio
Target base	cada 1.000 pasos del entorno
Epsilon	CartPole 1→0,05 / Acrobot 1→0,10

La ablación NO prueba por sí sola que el target es indispensable

-489,47

DQN base

Target 1.000 pasos: no alcanza -100

-500

Sin target

Ablación: también falla

-88,39

Target 250

Tres semillas superan -100

Inferencia permisible: con esta arquitectura y LR, sincronizar más frecuentemente mejoró el resultado observado.

Cuatro límites que un tribunal puede cuestionar

N = 3 semillas

Estimación de variabilidad frágil; no confundir episodios con réplicas.

OFAT, no factorial

No cuantifica interacciones entre learning rate y target cadence.

80k vs 200k

Entrenamientos nuevos con calendario epsilon también ampliado.

Métricas de reloj

El wall-clock incluye evaluaciones de duración dependiente de la política.

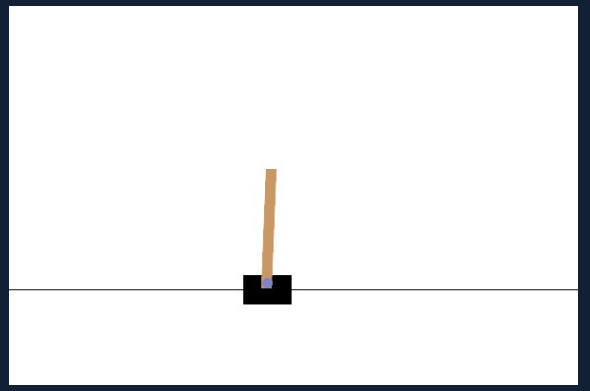
Cuantificar la explosión de acciones discretizadas

11 niveles hipotéticos por coordenada de acción; dimensiones reales de Gymnasium.

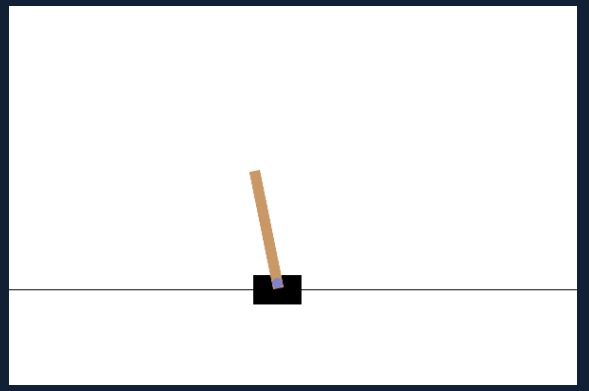
Entorno (versión)	Dimensiones y acciones con 11 niveles
Hopper-v5	11 obs. / 3 torques → 1.331 acciones
BipedalWalker-v3	24 obs. / 4 torques → 14.641 acciones
HalfCheetah-v5	17 obs. / 6 torques → 1.771.561 acciones
Ant-v5 (default)	105 obs. / 8 torques → 214.358.881 acciones

Para acciones continuas: PPO (política) | SAC (entropía) | TD3 (doble crítico)

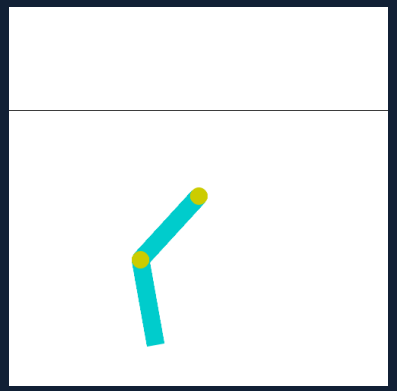
Los GIF ilustran políticas entrenadas, no sustituyen métricas



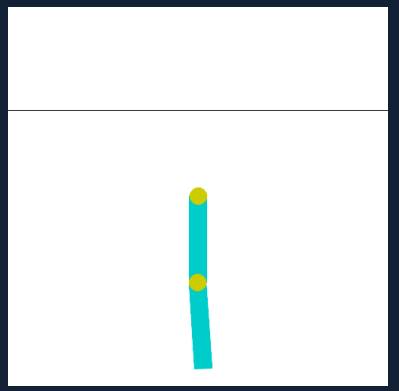
CartPole | Tabular 10 (80k)



CartPole | DQN (80k)



Acrobot | Target 250



Acrobot | DQN base

Cinco preguntas difíciles y respuestas breves

¿Por qué no una red neuronal mejor?	Capacidad no basta; optimización y bootstrapping importan.
¿Qué significa -500?	Horizonte sin resolver objetivo; no prueba ausencia total de aprendizaje.
¿Por qué no reportar accuracy?	El retorno acumulado es la métrica de control secuencial.
¿Tres semillas bastan?	Cumplen el mínimo del curso; no para inferencia fuerte.
¿DQN falló, entonces es peor?	No: falló esta configuración, no toda la familia.

Fuentes, entregables y comprobaciones finales

Recurso	Ubicación / referencia
Modelo	rl01/dqn.py y rl01/tabular.py
Entrenamiento	rl01/training.py y rl01/cli.py
Datos Tier 1	results/tier1 y results/tier1_200k
Datos Tier 2	results/tier2
Material cualitativo	4 GIF reales en results/tier1 y tier2

Referencias: Sutton y Barto (2018) | Mnih et al. (2015) | Gymnasium | van Hasselt et al. (2016)